

Aula sobre Probabilidade

É difícil fazer ciência de dados sem algum tipo de entendimento de probabilidade e sua matemática.

Para nossos propósitos, você deve pensar em probabilidade como ***uma forma de quantificar a incerteza associada a eventos escolhidos de um universo de eventos***. Em vez de obter informações técnicas sobre o significado desses termos, pense no ato de jogar um dado. O **universo** consiste em todos os resultados possíveis. E qualquer subconjunto desses resultados é um **evento**; por exemplo, "**parar no número um**" ou "**parar em um número par**".

No que diz respeito a **notação**, escrevemos **P(E)** para significar "**a probabilidade do evento E**". Usamos a teoria das probabilidades para construir e avaliar modelos. A verdade é que nós vamos usar a teoria da probabilidade em todo o lugar.

Também podemos definir probabilidade nos seguintes termos:

A repetição de um experimento, mesmo sob condições semelhantes, poderá levar a resultados (eventos) diferentes. Mas se o experimento for repetido um número "suficientemente grande" de vezes haverá uma regularidade nestes resultados que permitirá calcular a sua probabilidade de ocorrência

Definição Clássica

Se um experimento aleatório puder resultar em n diferentes e igualmente prováveis resultados, e n_{E_i} destes resultados referem-se ao evento E_i , então a probabilidade do evento E_i ocorrer será:

$$P(E_i) = \frac{n_{E_i}}{n}$$

O problema reside em calcular o número total de resultados possíveis e o número de resultados associados ao evento de interesse. Isso pode ser feito usando técnicas de análise combinatória ou por considerações teóricas ("bom senso").

Exemplo

Seja o seguinte Experimento Aleatório: lançamento de um dado não viciado e observação da face voltada para cima. Calcular as probabilidades de ocorrência dos seguintes eventos:

- Face 1
- Face par
- Face menor ou igual a 2

O Espaço Amostral deste experimento será: $s = \{1, 2, 3, 4, 5, 6\}$. Sendo assim há um total de 6 resultados possíveis, resultando em $n = 6$. Basta então definir quantos resultados estão associados a cada evento para que seja possível calcular suas probabilidades pela definição clássica.

O evento “face 1” tem apenas um resultado associado: $\{1\}$.

Então $n_{Ei} = 1$, e a probabilidade de ocorrer a face 1 será:

$$P(Ei) = n_{Ei}/n = 1/6$$

O evento “face par” tem três resultados associados: $\{2, 4, 6\}$.

Então $n_{Ei} = 3$, e a probabilidade de ocorrer face par será:

$$P(Ei) = n_{Ei}/n = 3/6$$

O evento “face menor ou igual a 2” tem dois resultados associados: $\{1, 2\}$.

Então $n_{Ei} = 2$, e a probabilidade de ocorrência de face menor ou igual a 2 será:

$$P(Ei) = n_{Ei}/n = 2/6 = 1/3$$

Experimento Aleatório

Experimento Aleatório é um processo de obtenção de um resultado ou medida que apresenta as seguintes características:

- Não se pode afirmar, ANTES de realizar o experimento, qual será o resultado de uma realização, mas é possível determinar o conjunto de resultados possíveis.
- Quando é realizado um grande número de vezes (replicado) apresentará uma REGULARIDADE que permitirá construir um modelo probabilístico para analisar o experimento.

São experimentos aleatórios: lançamento de um dado não viciado e observação da face voltada para cima; cruzar espécimes de ervilha e observar os fenótipos dos descendentes.

Espaço Amostral

Espaço Amostral é o conjunto de TODOS os resultados possíveis de um experimento aleatório. “PARA CADA EXPERIMENTO ALEATÓRIO HAVERÁ UM ESPAÇO AMOSTRAL ÚNICO ASSOCIADO A ELE “.

Exemplo

Definir os espaços amostrais dos experimentos abaixo:


1. Lançar uma moeda e observar a face voltada para cima.
Os dois únicos resultados possíveis são cara e coroa: $s = \{\text{Cara}, \text{Coroa}\}$.
2. Altura de homens adultos.
De uma forma genérica poderíamos definir indivíduo adulto como tendo mais de 1,40m de altura: $s = \{\text{Altura} > 1,40\text{m}\}$
3. Observar o número de meninos em famílias de 5 filhos.
Cada família pode ter no mínimo 0 e no máximo 5 meninos: $s = \{0, 1, 2, 3, 4, 5\}$

Evento


Evento é QUALQUER subconjunto do espaço amostral. Um evento pode conter um ou mais resultados, se pelo menos um dos resultados ocorrer o evento ocorre! Geralmente há interesse em calcular a probabilidade de que um determinado evento venha a ocorrer, e este evento pode ser definido de forma verbal, precisando ser “traduzido” para as definições da Teoria de Conjuntos, que veremos a seguir.

Seja o Experimento Aleatório lançamento de um dado não viciado e observação da face voltada para cima: o seu espaço amostral será $S = \{1, 2, 3, 4, 5, 6\}$. Definindo três eventos: $E_1 = \{2, 4, 6\}$, $E_2 = \{3, 4, 5, 6\}$ e $E_3 = \{1, 3\}$ serão apresentadas as definições de Evento União, Evento Intersecção, Eventos Mutuamente Exclusivos e Evento Complementar.

Evento União de E_1 com E_2 ($E_1 \cup E_2$): evento que ocorre se E_1 OU E_2 OU ambos ocorrem.



Evento Intersecção de E_1 com E_2 ($E_1 \cap E_2$): evento que ocorre se E_1 E E_2 ocorrem **SIMULTANEAMENTE**.



Eventos Mutuamente Exclusivos (M.E.): são eventos que **NÃO PODEM OCORRER SIMULTANEAMENTE**, não apresentando elementos em comum (sua intersecção é o conjunto vazio).

Dentre os três eventos definidos acima, observamos que os eventos E_1 e E_3 não têm elementos em comum:

$E_3 = \{1, 3\}$ $E_1 = \{2, 4, 6\}$ $E_1 \cap E_3 = \text{vazio} \Rightarrow E_1$ e E_3 são mutuamente exclusivos

Evento Complementar de um evento qualquer é formado por todos os resultados do espaço amostral que **NÃO PERTENCEM** ao evento. A união de um evento e seu complementar formará o próprio Espaço Amostral, e a intersecção de um evento e seu complementar é o conjunto vazio.




Figura 3 - Evento complementar

Dependência e Independência

Grosso modo, dizemos que dois eventos **E** e **F** são **dependentes** se saber algo sobre se o evento **E** acontece nos dá informações sobre a ocorrência do evento **F** (e vice-versa). Caso contrário, eles são **independentes**.



Por exemplo, considere um cenário com uma sacola na qual há 5 bolas sendo 3 verdes e 2 amarelas e dois eventos tirar uma bola verde, ou seja tirar uma bola verde duas vezes seguida. Esses podem ser considerados independentes ou dependentes e o que determina como serão considerados é o que se faz com a bola tirada da sacola.

Se, após o primeiro evento, devolvermos a bola na sacola então os eventos são **independentes** caso contrário eles são considerados **dependentes**.

Matematicamente, dizemos que dois eventos **E** e **F** são **independentes** se a probabilidade de que ambos ocorram seja o produto das probabilidades que cada um deles acontece:

$$P(E, F) = P(E)P(F)$$

No exemplo acima, considerando que devolvemos a bola na sacola, a probabilidade da “primeira bola ser verde” é $3/5$, e a probabilidade de “ambas serem verde” é $9/25$, mas a probabilidade de “primeira ser amarela e ambas serem verde” é 0.

Eventos Independentes

Dois ou mais eventos são independentes quando a ocorrência de um dos eventos não influencia a probabilidade de ocorrência dos outros. Se dois eventos A e B são independentes então a probabilidade de A ocorrer dado que B ocorreu é igual à própria probabilidade de ocorrência de A, e a probabilidade de B ocorrer dado que A ocorreu é igual à própria probabilidade de ocorrência de B.

Se A e B são independentes então:

- $P(A|B) = P(A)$ e $P(B|A) = P(B)$
- $P(A \cap B) = P(A) \times P(B|A) = P(A) \times P(B)$
- $P(A \cap B) = P(B) \times P(A|B) = P(B) \times P(A)$

AS EXPRESSÕES ACIMA SÃO VÁLIDAS SE E SOMENTE SE OS EVENTOS A E B FOREM INDEPENDENTES!

Em situações práticas dois eventos são independentes quando a ocorrência de um deles não modifica o Espaço Amostral do Experimento Aleatório.

Probabilidade Condicional

Muitas vezes há interesse de calcular a probabilidade de ocorrência de um evento B qualquer, sabendo (ou supondo) que um outro evento A ocorreu previamente. Em outras palavras queremos calcular a probabilidade de ocorrência de B CONDICIONADA à ocorrência prévia de A, simbolizada por $P(B | A)$ - lê-se probabilidade de B dado A - e a sua expressão será:

$$P(B | A) = \frac{P(B \cap A)}{P(A)} \quad \text{para } P(A) > 0$$

A probabilidade de ocorrência de B **condicionada à ocorrência de A** será igual à probabilidade da intersecção entre B e A, dividida pela probabilidade de ocorrência de A (o evento que já ocorreu).

Exercício

Dado dois lançamentos sequenciais de uma moeda honesta (justa), calcule a probabilidade de sair cara em ambos lançamentos sabendo que o primeiro lançamento é cara.

Escreva um código em Python que comprove o resultado.

Dica: use a função abaixo para criar o efeito aleatorio do lançamento de uma moeda

```
In [ ]: import random
import matplotlib.pyplot as plt
import math

def random_coin():
    return random.choice(["cara", "coroa"])

ambas_cara = 0
primeira_cara = 0

random.seed(0)
for _ in range(10000):
    primeira = random_coin()
    segunda = random_coin()
    if primeira == "cara":
        primeira_cara += 1
    if primeira == "cara" and segunda == "cara":
        ambas_cara += 1

print("P(ambas cara | primeira cara):", round(ambas_cara / primeira_cara, 1))
```

Exercício

Calcule a probabilidade de, em um lançamento de dois dados honestos, a soma das faces ser 6 sabendo-se que ambas as faces apresentam valores par.

Nesse caso, a evento A é a soma dos dados dar 6, enquanto o evento B é que os dois apresentem um resultado par, certo?

Solução:

Os possíveis resultados para as faces são 36 (seis opções para o primeiro dado x seis opções para o segundo).

As seguintes combinações somam 6: {1,5}, {2,4}, {3,3}, {4,2} e {5,1}. Ou seja, 5/36. Esse é $P(A)$

Já as possibilidades de os dois darem resultado par são: {2,2}, {2,4}, {2,6}, {4,2}, {4,4}, {4,6}, {6,2}, {6,4}, {6,6}. No fim das contas, são 9/36 chances. Esse é $P(B)$.

Agora, quais as opções que atendem aos dois requisitos? Somente {2,4} e {4,2}, certo? São 2/36. Esse resultado é $P(A \cap B)$. Colocando isso na fórmula, temos:

$$P(A|B) = P(A \cap B) / P(B)$$

$$P(A|B) = (2/36) / (9/36)$$

$$P(A|B) = (2/36) \cdot (36/9)$$

$$P(A|B) = (2/36) \cdot (36/9)$$

$$P(A|B) = 2/9$$

Então o resultado da probabilidade condicional para essa questão é 2/9 de chances ou 22,22% de chance.

</div>

Teorema de Bayes

A ideia principal do Teorema de Bayes é inverter as probabilidades condicionais.

Por exemplo, queremos saber a probabilidade $P(X|Y)$ mas conhecemos apenas a probabilidade de $P(Y|X)$.

Antes, vamos reescrever a nossa fórmula da probabilidade condicional para utilizarmos de uma forma melhor. Vamos passar o denominador multiplicando para o outro lado da equação:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A|B) \cdot P(B) = P(A \cap B)$$

e também

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

$$P(B|A) \cdot P(A) = P(B \cap A)$$

$$\text{Note que } P(B \cap A) = P(A \cap B)$$

Então podemos concluir que :

$$P(B \cap A) = P(A \cap B) = P(B|A) \cdot P(A) = P(A|B) \cdot P(B)$$

Variação da regra da probabilidade condicional.

Dado que conhecemos $P(A|B)$, queremos descobrir $P(B|A)$, para isso vamos usar o que aprendemos com a variação da regra da probabilidade condicional e montar a tão famosa fórmula do Teorema de Bayes:

$$\text{Sabendo que : } P(A \cap B) = P(B|A) \cdot P(A)$$

Podemos fazer :


$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

E assim obtemos o **Teorema de Bayes** :

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

A figura abaixo retrata o teorema de bayes em imagens, de modo a ilustrar a ideia por trás do teorema

P, Conditional P, and Derivation of Bayes' Theorem in Pictures



10

Exemplo

Imagine uma certa doença que afeta 1 em cada 10.000 pessoas. E imagine que exista um teste para essa doença cujo resultado é correto ("doente" se você tiver a doença, "sem doença", se você não a tiver) em 99% do tempo.

Qual a probabilidade de alguém estar doente em um teste positivo?

Vamos usar **T** para o evento "o teste é positivo" e **D** para o evento "tem a doença".

Então, o teorema de Bayes diz que a probabilidade de você ter a doença, condicionada a testes positivos, é:

$$P(D | T) = P(T | D)P(D) / [P(T | D)P(D) + P(T | \neg D)P(\neg D)]$$

Sabemos que:

- $P(T|D) = 0,99$ - Possibilidade de alguém com a doença testar positivo
- $P(D) = 0,0001$ - Possibilidade de qualquer pessoa ter a doença
- $P(T|\text{Não } D) = 0,01$ - Possibilidade de alguém sem a doença testar positivo
- $P(\text{Não } D) = 0,9999$ - Possibilidade de qualquer pessoa NÃO ter a doença

Se você substituir esses números no Teorema de Bayes, você encontrará:

$$P(D \mid T) = 0.98 \%$$

Ou seja, menos de 1% das pessoas que testam positivo realmente têm a doença.

Exemplo

Imagine que um casal tem dois filhos. Qual a probabilidade dos dois filhos serem meninos dado que um deles é menino?

Para calcular essa probabilidade, precisamos definir alguns eventos e probabilidades. Vamos definir os eventos:

- A: dois filhos meninos (evento desejado)
- B: um dos filhos é um menino (evento dado)

Solução: Para calcular essa probabilidade, precisamos definir alguns eventos e probabilidades. Vamos definir os eventos:

A: dois filhos meninos (evento desejado)

B: um dos filhos é um menino (evento dado)

Definidos os eventos, vamos definir algumas das probabilidades que precisamos para o cálculo:

P(A): probabilidade de que os dois filhos sejam meninos

P(B): probabilidade de que um filho seja um menino

Com cálculos simples, chegamos à conclusão de que a probabilidade de que dois filhos sejam meninos é $\frac{1}{4}$.

Assumindo que a probabilidade de que uma criança seja menino seja $\frac{1}{2}$, então a probabilidade de que pelo menos um dos filhos do casal seja um menino é $\frac{3}{4}$.

Podemos concluir também que $P(B|A)$, ou seja, a probabilidade de que um dos filhos seja menino dado que os dois são meninos é 1.

Sendo assim, temos:

- $P(A) = \frac{1}{4}$
- $P(B) = \frac{3}{4}$
- $P(B|A) = 1$

Logo, aplicando o Teorema de Bayes:

$$P(A|B) = \frac{1 \times \frac{1}{4}}{\frac{3}{4}} = \frac{1}{3}$$

In []: